

למידה חישובית 1 (096411)

חורף תשפ"ה 2025

תרגיל בית 4

תאריך אחרון להגשה: 16/01/2025 בשעה 23:59

הוראות הגשה

- ההגשה בזוגות בלבד, דרך "קבוצה" ייעודית שיצרתם במודל.
- עליכם להגיש קובץ pdf בודד:
 - HW4_ID1_ID2.pdf – קובץ המכיל תשובות לכל השאלות. עבור שאלה 3, יש להוסיף צילומי מסך של הקוד והפלטים שהוא מפיק. ניתן גם לייצא מחברת בפורמט PDF ולשרשר אותה לתשובות לחלק היבש.
- קוד חייב להיות קריא, תמציתי ומתועד היטב. יש להקפיד על שימוש בשמות משמעותיים למשתנים.
- כל גרף חייב להכיל לפחות את האלמנטים הבאים: כותרת, מקרא (legend), כותרות לצירים ויחידות (ticks).
- יש להשתמש בפורום במודל לטובת שאלות על התרגיל. השאלות שלכם עוזרות לסטודנטים אחרים בקורס.



שאלה 1

בהרצאות למדנו על **(Regularized Loss Minimization (RLM)** וראינו כיצד באמצעות שיטה זו ניתן לקבל לומדים יציבים ולמתן את תופעת ה-**overfitting**.

תהי $l(w, x, y)$ פונקציה קמורה ב- w (כאשר x, y מתייחסים ל x, y בקבועים). יהי $S = \{(x_i, y_i)\}_{i=1}^m$ מדגם אימון ותהי (x', y') תצפית נוספת. בהינתן S , נגדיר את: $f_S(w) = L_S(w) + \lambda \|w\|^2$ כאשר: $L_S(w) = \frac{1}{m} \sum_{i=1}^m l(w, x_i, y_i)$.
כמו כן נגדיר את $A(S) = \operatorname{argmin}_w f_S(w)$. בנוסף, בהינתן $i \in \{1, \dots, m\}$ נגדיר את $S^{(i)}$ באופן הבא:

$$S^{(i)} = \{(x_1, y_1), \dots, (x_{i-1}, y_{i-1}), (x', y'), (x_{i+1}, y_{i+1}), \dots, (x_m, y_m)\}$$

ונגדיר את $A(S^{(i)}) = \operatorname{argmin}_w f_{S^{(i)}}(w)$.

א. הסבירו במילותיכם מה הוא $S^{(i)}$ ומה הוא $A(S)$.

ב. הסבירו את נכונות השוויון הבא לכל u, v, i :

$$f_S(v) - f_S(u) = L_{S^{(i)}}(v) + \lambda \|v\|^2 - (L_{S^{(i)}}(u) + \lambda \|u\|^2) + \frac{l(v, x_i, y_i) - l(u, x_i, y_i)}{m} + \frac{l(u, x', y') - l(v, x', y')}{m}$$

ג. בשימוש הטענה הנ"ל, הסבירו מדוע אי השוויון הבא נכון:

$$f_S(A(S^{(i)})) - f_S(A(S)) \leq \frac{l(A(S^{(i)}), x_i, y_i) - l(A(S), x_i, y_i)}{m} + \frac{l(A(S), x', y') - l(A(S^{(i)}), x', y')}{m}$$

ד. הוכיחו כי:

$$\lambda \|A(S^{(i)}) - A(S)\|^2 \leq \frac{l(A(S^{(i)}), x_i, y_i) - l(A(S), x_i, y_i)}{m} + \frac{l(A(S), x', y') - l(A(S^{(i)}), x', y')}{m}$$

ה. הוכיחו כי אם $l(\cdot)$ היא פונקציה $Lipschitz$ - ρ אזי:

$$\|A(S^{(i)}) - A(S)\| \leq \frac{2\rho}{\lambda m}$$

ו. הוכיחו כי אם $l(\cdot)$ היא פונקציה $Lipschitz$ - ρ אזי: $l(A(S^{(i)}), x_i, y_i) - l(A(S), x_i, y_i) \leq \frac{2\rho^2}{\lambda m}$

ז. כעת נגדיר $L_D(w) = E_{(x,y) \sim D}[l(w, x, y)]$ ו- $L_S(w) = \frac{1}{m} \sum_{i=1}^m [l(w, x_i, y_i)]$. הסבירו במילותיכם מה משמעות כל אחת מההגדרות. קבעו האם בהינתן מדגם אימון S ולומד w ניתן לחשב את ערך הביטוי או לא. נמקו.

ח. כעת הניחו כי $i \sim U(m)$ וכי ניתן לדגום את $(x', y') \sim D$ באופן בלתי תלוי ב- S . הוכיחו כי:

$$E_{S \sim D^m}[L_D(A(S)) - L_S(A(S))] \leq \frac{2\rho^2}{\lambda m}$$

שאלה 2

- בשאלה זו נדון במשמעות של מטריקות שונות (כגון precision) ונדגים שרטוט של עקומת ROC בבעיות סיווג בינאריות.
- א. כתבו את הנוסחאות של כל אחת מהמטריקות הבאות: precision, recall, TPR. השתמשו בסימונים מתוך מטריצת הבלבול TP, TN, FP, FN – (confusion matrix). הסבירו במילותיכם מה כל מטריקה מייצגת. עבור כל מטריקה, ציינו האם אנו רוצים למקסם או למזער אותה.
- ב. תנו דוגמה (במילים) למשימת סיווג בינארית בה ה-recall חשוב יותר מה-precision. הצדיקו את ההצעה שלכם.
- ג. תנו דוגמה (במילים) למשימת סיווג בינארית בה ה-precision חשוב יותר מה-recall. הצדיקו את ההצעה שלכם.
- ד. כעת הניחו שאימנתם מודל רגרסיה לוגיסטית על מדגם אימון בעל 2 פיצ'רים - x_1, x_2 . לאחר האימון התקבלו המשקולות הבאות:

$$w_0 = -0.3, w_1 = -0.5, w_2 = 0.5$$

מדגם האימון נראה כך:

	x_1	x_2	y
0	8	2	0
1	2	4	1
2	16	2	1
3	4	2	0
4	9	2	0

- ד. כתבו את הנוסחה עבור $P_w(y = 1|x)$ עם המשקולות הנ"ל וחשבו את $P_w(y_i = 1|x_i)$ לכל אחת מהתצפיות $i \in \{1, \dots, 5\}$.
- ה. שרטטו (בדף ועט או באמצעי אלקטרוני שאיננו תכנותי) את עקומת ה-ROC עבור המודל והתצפיות הנ"ל. יש לשרטט בנוסף את העקומה עבור מודל אקראי. שימו לב כי יש לחשב את ערכי ה-FPR וה-TPR עבור שרטוט זה. פרטו את חישוביכם.
- ו. חשבו את ערך המטריקה AUC-ROC, ופרטו את חישוביכם. האם נדמה שהמודל טוב יותר ממודל אקראי? נמקו.

שאלה 3

בשאלה זו ניישם שימוש ב cross validation על סט הנתונים Fashion-MNIST. סט נתונים זה, מכיל כ-70,000 תמונות שחור לבן של 10 סוגים של פרטי לבוש. כל תמונה מלווה בתיוג של סוג פריט הלבוש שמופיע בה.

דוגמה מתוך סט הנתונים (ללא תיוגים):



כל תמונה מיוצגת ע"י מטריצה דו מימדית מגודל 28×28 עם ערכים בין 0 ל-255 (כאשר 0 מייצג פיקסל שחור לחלוטין ו-255 מייצג פיקסל לבן לחלוטין). בשאלה זו נעבוד עם ייצוג שטוח של המטריצות הדו מימדיות, כלומר כל תמונה תיוצג ע"י וקטור חד מימדי מגודל $28 \times 28 = 784$. נשתמש בקומבינציות שונות של kernels והיפר-פרמטרים שונים עבור אלגוריתם SVM על מנת לקבוע איזה מסווג צפוי להיות הטוב ביותר.

א. השתמשו בקטע הקוד הבא בכדי לטעון 7000 תמונות ותוויות מתוך סט הנתונים:

```
import numpy as np
from sklearn.datasets import fetch_openml

def fetch_mnist():
    #Download MNIST dataset
    X, y = fetch_openml('Fashion-MNIST', version=1, return_X_y=True)
    X = X.to_numpy()
    y = y.to_numpy()

    # Randomly sample 7000 images
    np.random.seed(2)
    indices = np.random.choice(len(X), 7000, replace=False)
    X, y = X[indices], y[indices]
    return X, y

X, y = fetch_mnist()
print(X.shape, y.shape)
```

יש לוודא שקטע הקוד מדפיס את הפלט הבא: $(7000, 784)$ $(7000,)$. ייתכן והטעינה תיקח מספר שניות.

ב. הציגו את 10 התצפיות (תמונות) הראשונות מהמדגם X באמצעות הפונקציה `plt.imshow` עם הארגומנט `cmap="binary"` שימו לב כי יש לשנות את הצורה (`reshape`) של כל תצפית ב- X בחזרה למימד 28×28 על מנת להציג אותה באמצעות הפונקציה `imshow`. לכל תמונה, הציגו בסמוך אליה את התיג המתאים שלה מ- γ בצורה הבאה: `(class_index, class_name)`.

אתם יכולים להיעזר במילון הבא:

```
idx2class={'0': 'T-shirt/top', '1': 'Trouser', '2': 'Pullover', '3': 'Dress', '4': 'Coat', '5': 'Sandal', '6': 'Shirt', '7': 'Sneaker', '8': 'Bag', '9': 'Ankle'}
```

ג. ממשו פונקציה בשם `SVM_results(X_train, y_train, X_test, y_test)` כאשר:

- $X_{train} \in R^{m_{train} \times 784}$ – מטריצת הנתונים עבור סט האימון (מטיפוס numpy nd-array)
- $y_{train} \in R^{m_{train}}$ – וקטור הלייבלים עבור סט האימון (מטיפוס numpy nd-array)
- $X_{test} \in R^{m_{test} \times 784}$ – מטריצת הנתונים עבור סט המבחן (מטיפוס numpy nd-array)
- $y_{test} \in R^{m_{test}}$ – וקטור הלייבלים עבור סט המבחן (מטיפוס numpy nd-array)

על הפונקציה להשתמש בפונקציה `cross_validation_error(X, y, model, folds)` בתרגיל בית 3 עם `folds=4` בכדי לחשב את שגיאות האימון והולידציה הממוצעת של מסווגי SVM עם היפר-פרמטרים הבאים:

- קרנל לינארי עם ערך C ברירת מחדל
- קרנל פולינומי עבור ערכי $d \in \{2, 4, 6, 8\}$
- קרנל RBF עבור ערכי $\gamma \in \{0.001, 0.01, 0.1, 1.0, 10\}$

סה"כ 10 מודלים שונים. בנוסף, לכל מודל מהנ"ל, הפונקציה צריכה להתאים את אותו המודל עבור כל מדגם האימון ולחשב את שגיאת המבחן. הפונקציה צריכה להחזיר מילון (dictionary) כאשר המפתחות (`keys`) הם שמות המודל (לדוגמא: `'SVM_poly_4'` והערכים (`values`) הינם tuple מהצורה הבאה:

```
(average_train_error, average_validation_error, test_error)
```

כאשר 2 האלמנטים הראשונים מחושבים ע"י CV-fold 4 והאלמנט האחרון מחושב ע"י מודל בודד שמתאמן על כל מדגם האימון.

שימו לב כי בדומה לתרגיל בית 3, במימוש של הפונקציה `cross_validation_error` אסור לכם להשתמש בפונקציות עזר מהספרייה `sklearn`. בפרט אסור לכם להשתמש בפונקציה `cross_val_score` מתוך `sklearn`. עם זאת, אתם יכולים להשוות את הפלטמים שלכם לפלטמים של הפונקציות הרלוונטיות מהספרייה. כמו כן, בפונקציה `SVM_results` מותר (ובדאי) להשתמש בפונקציות ומחלקות מ `sklearn`.

ד. חלקו את סט הנתונים לסט אימון וסט מבחן באמצעות הפקודה הבאה:

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, random_state=42)
```

הריצו את הפונקציה מסעיף ב' על הנתונים שטענתם בסעיף א'. ייתכן והריצה תיקח הרבה זמן (~שעה).

ציירו גרף עמודות (`bar plot`) המציג את התוצאות של כל ניסוי. כלומר, ציר ה- x יתאר את מודלי ה-SVM השונים שאימנם וציר ה- y יתאר את שגיאת האימון הממוצעת, שגיאת הולידציה הממוצעת ושגיאת המבחן (סה"כ 10 שלשות של עמודות). יש להקפיד על צבע שונה לכל סוג של עמודה (אימון / ולידציה / מבחן).

מיהו המודל הטוב ביותר לפי שיטת CV? מיהו המודל הטוב ביותר על מדגם המבחן? האם מדובר באותו המודל?